Tarea M22-CD - YAIR PALOMARES

```
import pandas as pd
import pylab as pl
import numpy as np
import scipy.optimize as opt
from sklearn import preprocessing
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings("ignore")
import os
os.chdir("C:/Users/yair_/OneDrive/Desktop/Ciencia de Datos/Módulo 21 - KNN y métricas de clasificación")
```

- Cargue la base de datos en Python y asegúrese de re-codificar las variables categóricas de manera pertinente antes de iniciar su análisis (Sugerencia: Use "pd.get_dummies")

```
data = pd.read_csv("recursos_humanos.csv")
data
```

	satisfaction_level	last_evaluation	number_project	average_montly_hours	time_spend_company	Work_accident	left	promotion_last_5years	sales	salary
0	0.38	0.53	2	157	3	0	1	0	sales	low
1	0.80	0.86	5	262	6	0	1	0	sales	medium
2	0.11	0.88	7	272	4	0	1	0	sales	medium
3	0.72	0.87	5	223	5	0	1	0	sales	low
4	0.37	0.52	2	159	3	0	1	0	sales	low
...	...	...	...	...	...	...	...	...	...	...
14994	0.40	0.57	2	151	3	0	1	0	support	low
14995	0.37	0.48	2	160	3	0	1	0	support	low
14996	0.37	0.53	2	143	3	0	1	0	support	low
14997	0.11	0.96	6	280	4	0	1	0	support	low
14998	0.37	0.52	2	158	3	0	1	0	support	low

```python
#Normalización de columnas faltantes
data["average_montly_hours"] = (data["average_montly_hours"] - np.min(data["average_montly_hours"])) / (np.max(data["average_montly_hours"]) - np.min(da
data["time_spend_company"] = (data["time_spend_company"] - np.min(data["time_spend_company"])) / (np.max(data["time_spend_company"]) - np.min(data["time_

#Se crean las variables dummy para las variables categóricas
number_project_dummy = pd.get_dummies(data["number_project"], prefix="Project", dtype= np.uint8)
number_sales_dummy = pd.get_dummies(data["sales"], prefix="Sales", dtype = np.uint8)
number_salary_dummy = pd.get_dummies(data["salary"], prefix="Salary", dtype = np.uint8)

#Se concatenan las columnas de las variables dummy creadas
data = pd.concat([data, number_project_dummy], axis=1)
data = pd.concat([data, number_sales_dummy], axis=1)
data = pd.concat([data, number_salary_dummy], axis=1)
data
```

	satisfaction_level	last_evaluation	number_project	average_montly_hours	time_spend_company	Work_accident	left	promotion_last_5years	sales	salary	...
0	0.38	0.53	2	0.285047	0.125	0	1	0	sales	low	...
1	0.80	0.86	5	0.775701	0.500	0	1	0	sales	medium	...
2	0.11	0.88	7	0.822430	0.250	0	1	0	sales	medium	...
3	0.72	0.87	5	0.593458	0.375	0	1	0	sales	low	...
4	0.37	0.52	2	0.294393	0.125	0	1	0	sales	low	...
...	...	...	...	...	...	...	...	...	...	...	...
14994	0.40	0.57	2	0.257009	0.125	0	1	0	support	low	...
14995	0.37	0.48	2	0.299065	0.125	0	1	0	support	low	...
14996	0.37	0.53	2	0.219626	0.125	0	1	0	support	low	...
14997	0.11	0.96	6	0.859813	0.250	0	1	0	support	low	...
14998	0.37	0.52	2	0.289720	0.125	0	1	0	support	low	...

```
#Análisis exploratorio de los datos para validar equilibrio
frec_left = pd.value_counts(data["left"])
etiquetas = list(data['left'].unique())
plt.pie(frec_left, labels=etiquetas , autopct="%0.1f %%")
plt.show
```

```
<function matplotlib.pyplot.show(close=None, block=None)>
```

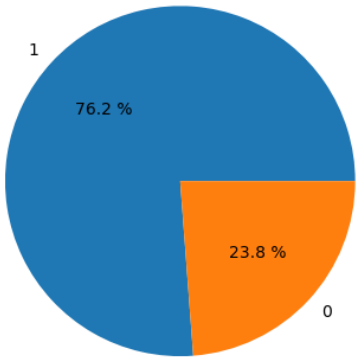


```
#Se eliminan las columnas de las variables categóricas
data.drop(["number_project", "sales", "salary"], axis=1, inplace=True)
```

```
#Análisis exploratorio
ax = data[data["left"] == 1][0:1000].plot(kind="scatter", x="satisfaction_level", y="last_evaluation", color="DarkBlue", label="Renuncia")
ax = data[data["left"] == 0][0:1000].plot(kind="scatter", x="satisfaction_level", y="last_evaluation", color="Yellow", label="Continua", ax=ax)
plt.show()
```

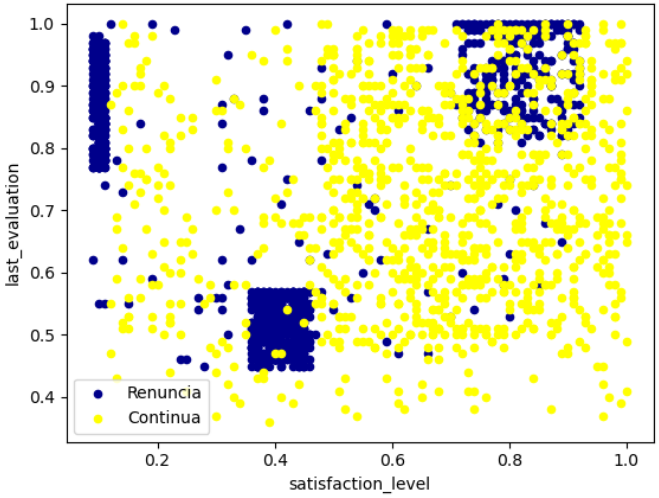

- Use el método de Máquinas de soporte vectorial para generar un modelo predictivo. Para dicho fin, pruebe los 4 diferentes tipos de Kernel discutidos en esta lección. En cada caso elabore un mapa de calor para las matrices de confusión así como un reporte de clasificación detallado. Interprete verbalmente sus indicadores.

```
#Se definen variables dependientes e independientes
y = data.left.values
x = data.drop(["left"], axis=1)

#Base de entrenamiento y prueba
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x,y,test_size=0.3, random_state=1)
```

Modelación con SVM

Modelo Lineal

```
from sklearn import svm
clf = svm.SVC(kernel="linear")
clf.fit(x_train, y_train)

#Predicción para la base de prueba
y_hat = clf.predict(x_test)

#Creación de matriz de confusión
from sklearn.metrics import confusion_matrix
y_pred = clf.predict(x) #Realiza las predicciones
cm = confusion_matrix(y_test, y_hat)
cm
```

```
array([[3123,  293],
       [ 401,  683]], dtype=int64)
```

```python
#Visualización de la matriz de confusión
import seaborn as sns
f, ax = plt.subplots(figsize=(5,5))

sns.heatmap(cm, annot=True, linewidths=0.5, linecolor="red", fmt=".0f", ax=ax)
plt.xlabel("y pronosticada")
plt.ylabel("y real")
plt.show()
```

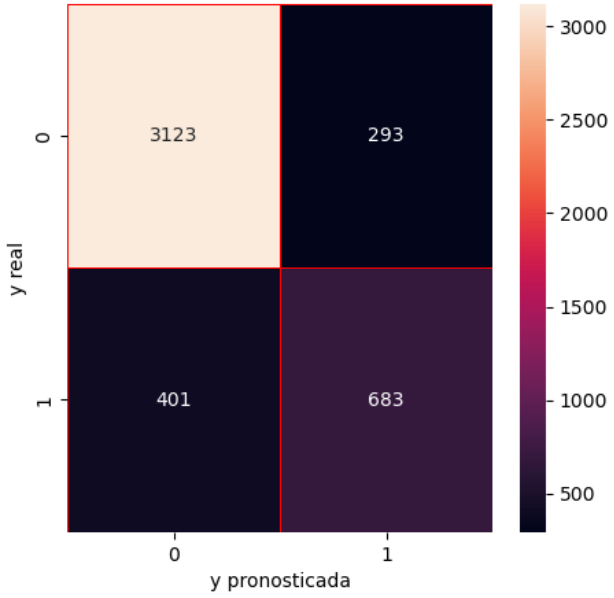


```python
from sklearn.metrics import classification_report
cnf_matrix = confusion_matrix(y_test, y_hat, labels=[0,1])
print(classification_report(y_test, y_hat))
```

```
              precision    recall  f1-score   support

           0       0.89      0.91      0.90      3416
           1       0.70      0.63      0.66      1084

    accuracy                           0.85      4500
   macro avg       0.79      0.77      0.78      4500
weighted avg       0.84      0.85      0.84      4500
```

A través del indicador de precisión, nos percatamos de que la aplicación del modelo lineal del algoritmo SVM permite predecir correctamente un 89% de los casos donde el trabajador decide no renunciar, mientras que es capaz de predecir correctamente en un 70% de las ocasiones los casos donde el trabajador toma la decisión de renunciar. Por otro lado, tomando como referencia el valor del indicador recall, del total de casos donde el trabajador no renunció, en el 91% de las ocasiones el algoritmo logró obtener el mismo resultado, mientras que para los casos donde el trabajador renuncia fue capaz de coincidir en un 63% de las ocasiones.

Con base en los dos indicadores anteriormente descritos, se obtuvo una evaluación del modelo de 90% para los casos de "No Renunciar", esto de acuerdo al indicador F1-score. Y un 66% de evaluación para los casos de "Renuncia".

Modelo Polynomial

```
#Modelo polynomial
clf = svm.SVC(kernel="poly")
clf.fit(x_train, y_train)

#Predicción para la base de prueba
y_hat = clf.predict(x_test)

#Creación de matriz de confusión
y_pred = clf.predict(x)
cm = confusion_matrix(y_test, y_hat)
cm
```

```
array([[3286,  130],
       [ 118,  966]], dtype=int64)
```

```
#Visualización de la matriz de confusión
f, ax = plt.subplots(figsize=(5,5))

sns.heatmap(cm, annot=True, linewidths=0.5, linecolor="red", fmt=".0f", ax=ax)
plt.xlabel("y pronosticada")
plt.ylabel("y real")
plt.show()
```

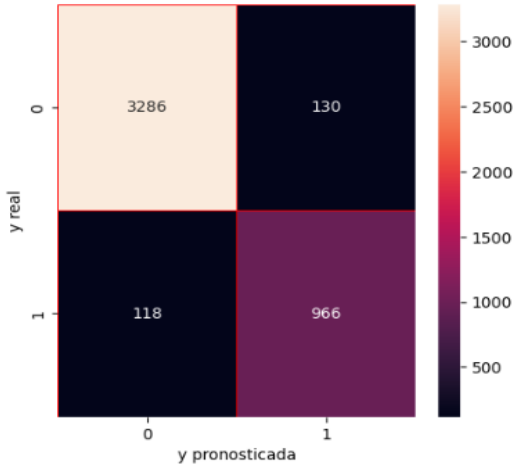


```
cnf_matrix = confusion_matrix(y_test, y_hat, labels=[0,1])
print(classification_report(y_test, y_hat))
```

```
              precision    recall  f1-score   support

           0       0.97      0.96      0.96      3416
           1       0.88      0.89      0.89      1084

    accuracy                           0.94      4500
   macro avg       0.92      0.93      0.92      4500
weighted avg       0.95      0.94      0.94      4500
```

A través del indicador de precisión, nos percatamos de que la aplicación del modelo polinomial del algoritmo SVM permite predecir correctamente un 97% de los casos donde el trabajador decide no renunciar, mientras que es capaz de predecir correctamente en un 88% de las ocasiones los casos donde el trabajador toma la decisión de renunciar. Por otro lado, tomando como referencia el valor del indicador recall, del total de casos donde el trabajador no renunció, en el 96% de las ocasiones el algoritmo logró obtener el mismo resultado, mientras que para los casos donde el trabajador renuncia fue capaz de coincidir en un 89% de las ocasiones.

Con base en los dos indicadores anteriormente descritos, se obtuvo una evaluación del modelo de 96% para los casos de "No Renunciar", esto de acuerdo al indicador F1-score. Y un 89% de evaluación para los casos de "Renuncia".

Modelo Radial Basis Function (RBF)

```
#Modelo RBF
clf = svm.SVC(kernel="rbf")
clf.fit(x_train, y_train)

#Predicción para la base de prueba
y_hat = clf.predict(x_test)

#Creación de matriz de confusión
y_pred = clf.predict(x)
cm = confusion_matrix(y_test, y_hat)
cm
```

```
array([[3283,  133],
       [ 148,  936]], dtype=int64)
```

```
#Visualización de la matriz de confusión
f, ax = plt.subplots(figsize=(5,5))

sns.heatmap(cm, annot=True, linewidths=0.5, linecolor="red", fmt=".0f", ax=ax)
plt.xlabel("y pronosticada")
plt.ylabel("y real")
plt.show()
```

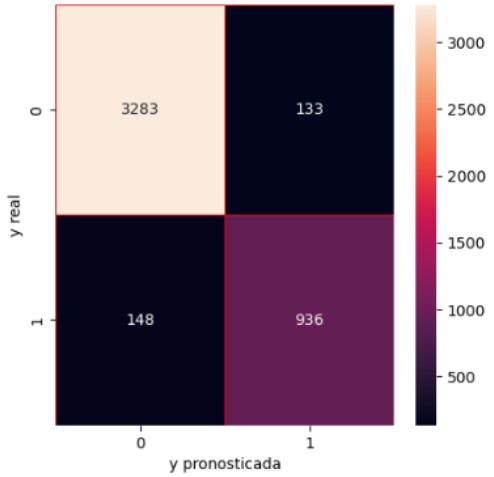


```
cnf_matrix = confusion_matrix(y_test, y_hat, labels=[0,1])
print(classification_report(y_test, y_hat))
```

```
              precision    recall  f1-score   support

           0       0.96      0.96      0.96      3416
           1       0.88      0.86      0.87      1084

    accuracy                           0.94      4500
   macro avg       0.92      0.91      0.91      4500
weighted avg       0.94      0.94      0.94      4500
```

A través del indicador de precisión, nos percatamos de que la aplicación del modelo RBF del algoritmo SVM permite predecir correctamente un 96% de los casos donde el trabajador decide no renunciar, mientras que es capaz de predecir correctamente en un 88% de las ocasiones los casos donde el trabajador toma la decisión de renunciar. Por otro lado, tomando como referencia el valor del indicador recall, del total de casos donde el trabajador no renunció, en el 96% de las ocasiones el algoritmo logró obtener el mismo resultado, mientras que para los casos donde el trabajador renuncia fue capaz de coincidir en un 86% de las ocasiones.

Con base en los dos indicadores anteriormente descritos, se obtuvo una evaluación del modelo de 96% para los casos de "No Renunciar", esto de acuerdo al indicador F1-score. Y un 87% de evaluación para los casos de "Renuncia".

Modelo Sigmoid ¶

```
#Modelo RBF
clf = svm.SVC(kernel="sigmoid")
clf.fit(x_train, y_train)

#Predicción para la base de prueba
y_hat = clf.predict(x_test)

#Creación de matriz de confusión
y_pred = clf.predict(x)
cm = confusion_matrix(y_test, y_hat)
cm
```

```
array([[2890,  526],
       [ 566,  518]], dtype=int64)
```

```
#Visualización de la matriz de confusión
f, ax = plt.subplots(figsize=(5,5))

sns.heatmap(cm, annot=True, linewidths=0.5, linecolor="red", fmt=".0f", ax=ax)
plt.xlabel("y pronosticada")
plt.ylabel("y real")
plt.show()
```

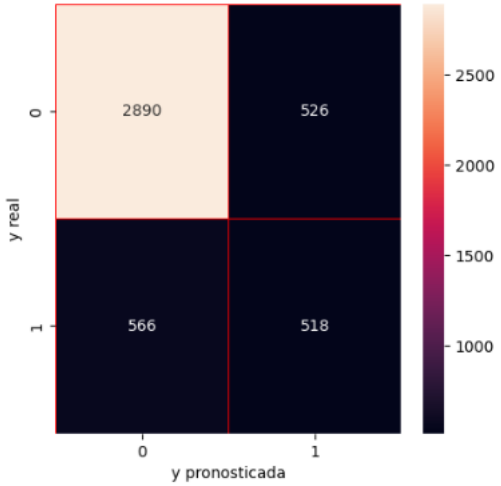


```
cnf_matrix = confusion_matrix(y_test, y_hat, labels=[0,1])
print(classification_report(y_test, y_hat))
```

```
              precision    recall  f1-score   support

           0       0.84      0.85      0.84      3416
           1       0.50      0.48      0.49      1084

    accuracy                           0.76      4500
   macro avg       0.67      0.66      0.66      4500
weighted avg       0.75      0.76      0.76      4500
```

A través del indicador de precisión, nos percatamos de que la aplicación del modelo sigmoid del algoritmo SVM permite predecir correctamente un 84% de los casos donde el trabajador decide no renunciar, mientras que es capaz de predecir correctamente en un 50% de las ocasiones los casos donde el trabajador toma la decisión de renunciar. Por otro lado, tomando como referencia el valor del indicador recall, del total de casos donde el trabajador no renunció, en el 85% de las ocasiones el algoritmo logró obtener el mismo resultado, mientras que para los casos donde el trabajador renuncia fue capaz de coincidir en un 48% de las ocasiones.

Con base en los dos indicadores anteriormente descritos, se obtuvo una evaluación del modelo de 84% para los casos de "No Renunciar", esto de acuerdo al indicador F1-score. Y un 49% de evaluación para los casos de "Renuncia".

¿Cuál resultó ser el modelo predictivo más adecuado? Explique su razonamiento.

```
#Comparación de modelos predictivos aplicados

diccionario = {"Precisión No Renuncia": [0.89, 0.97, 0.96, 0.84], "Precisión Renuncia": [0.70, 0.88, 0.88, 0.50],
               "Recall No Renuncia": [0.91, 0.96, 0.96, 0.85], "Recall Renuncia": [0.63, 0.89, 0.86, 0.48],
               "F1-Score No Renuncia": [0.90, 0.96, 0.96, 0.84], "F1-Score Renuncia": [0.66, 0.89, 0.87, 0.49]}
tabla_comparativa = pd.DataFrame(diccionario)
tabla_comparativa.index = ["Modelo Lineal", "Modelo Polinomial", "Modelo RBF", "Modelo Sigmoid"]
tabla_comparativa
```

	Precisión No Renuncia	Precisión Renuncia	Recall No Renuncia	Recall Renuncia	F1-Score No Renuncia	F1-Score Renuncia
Modelo Lineal	0.89	0.70	0.91	0.63	0.90	0.66
Modelo Polinomial	0.97	0.88	0.96	0.89	0.96	0.89
Modelo RBF	0.96	0.88	0.96	0.86	0.96	0.87
Modelo Sigmoid	0.84	0.50	0.85	0.48	0.84	0.49

Se concluye basados en los indicadores de evaluación considerados, que el modelo polinomial es el que mejor se ajusta a los datos, permitiendonos obtener una mejor precisión, recuperación y comportamiento general de la eficiencia del modelo. Si se ponderara una mayor importancia a detectar los casos de "Renuncia", aún así el mejor modelo continuaría siendo el modelo polinomial.

¿Qué resultado pronosticaría para un empleado con los siguientes indicadores?

satisfaction_level	last_evaluation	number_project	average_montly_hours	time_spend_company	Work_accident	promotion_last_5years	sales	salary
0.5.	0.75	4	200	4	0	0	sales	medium

```
#Pronóstico para empleado
data = pd.read_csv("recursos_humanos.csv")

#Se agrega la fila correspondiente al pronóstico
data.loc[14999] = [0.5,0.75,4,200,4,0,"NA",0,"sales","medium"]

#Normalización de columnas faltantes
data["average_montly_hours"] = (data["average_montly_hours"] - np.min(data["average_montly_hours"])) / (np.max(data["average_montly_hours"]) - np.min(da
data["time_spend_company"] = (data["time_spend_company"] - np.min(data["time_spend_company"])) / (np.max(data["time_spend_company"]) - np.min(data["time

#Se crean las variables dummy para las variables categóricas
number_project_dummy = pd.get_dummies(data["number_project"], prefix="Project", dtype= np.uint8)
number_sales_dummy = pd.get_dummies(data["sales"], prefix="Sales", dtype = np.uint8)
number_salary_dummy = pd.get_dummies(data["salary"], prefix="Salary", dtype = np.uint8)

#Se concatenan las columnas de las variables dummy creadas
data = pd.concat([data, number_project_dummy], axis=1)
data = pd.concat([data, number_sales_dummy], axis=1)
data = pd.concat([data, number_salary_dummy], axis=1)

#Se eliminan las columnas de las variables categóricas
data.drop(["number_project", "sales", "salary"], axis=1, inplace=True)

#Se definen variables dependientes e independientes
x = data.drop(["left"], axis=1)

#Se realiza pronóstico
y_pred = clf.predict(x.tail(1))

if y_pred == 0:
    print("Se predice que el empleado no renunciará")
else:
    print("Se predice que el empleado renunciará")
```

```
Se predice que el empleado no renunciará
```